

O Fine-Tuning Altera Apenas a Acurácia ou Também as Regiões Utilizadas por uma CNN?

Eduardo Jesus Dal Pizzol – 251008114

Matheus Lemes Amaral – 241031852

Universidade de Brasília – UnB

FGA0261 – Inteligência Artificial II

Resumo—O aprendizado por transferência é amplamente empregado em classificação de imagens, mas sua avaliação costuma se limitar ao desempenho preditivo. Este trabalho investiga se o ajuste completo de uma rede convolucional também modifica as regiões da imagem usadas em suas decisões. Uma ResNet-18 pré-treinada no ImageNet é avaliada no Oxford-IIIT Pet sob duas estratégias: extração de características com o backbone congelado e ajuste fino de todos os parâmetros. Além de acurácia, macro-F1 e calibração, mapas Grad-CAM são comparados com as máscaras de segmentação dos animais por energia no primeiro plano, pointing game e interseção sobre união. O protocolo permite distinguir ganho de desempenho de mudança efetiva na localização da evidência visual e identificar possível dependência do fundo. Os resultados serão reportados sobre três sementes e analisados de forma pareada.

Index Terms—redes neurais convolucionais, transferência de aprendizado, fine-tuning, Grad-CAM, explicabilidade

I. INTRODUÇÃO

Redes neurais convolucionais (CNNs) transformaram a classificação visual ao aprender representações diretamente dos pixels [1]. Arquiteturas residuais permitiram treinar modelos mais profundos e tornaram-se backbones comuns em aprendizado por transferência [2]. Nesse cenário, um modelo pré-treinado em grande escala é adaptado para uma tarefa com menos dados, congelando o extrator de características ou ajustando seus parâmetros.

Embora modelos com melhor desempenho no ImageNet geralmente apresentem melhor transferência, essa relação depende da tarefa e do procedimento de adaptação [3]. Comparações baseadas somente em acurácia não mostram se o modelo aprendeu evidências semanticamente adequadas. Uma CNN pode melhorar a classificação explorando correlações do fundo em vez das características do objeto.

O Grad-CAM produz mapas de importância espacial a partir dos gradientes da classe em relação às ativações convolucionais [4]. Entretanto, mapas visualmente plausíveis não são evidência suficiente de explicabilidade, pois alguns métodos de saliência podem ser pouco sensíveis aos parâmetros aprendidos [5]. Por isso, este trabalho combina inspeção qualitativa e métricas calculadas contra máscaras de segmentação.

São investigadas duas perguntas: **RQ1**: o fine-tuning completo melhora a classificação em relação ao backbone congelado? **RQ2**: ele altera a localização da evidência visual e seu alinhamento com o animal? A contribuição é um protocolo reproduzível que relaciona desempenho, calibração e atenção

espacial em pares de modelos com a mesma arquitetura e inicialização pré-treinada.

II. MATERIAIS E MÉTODOS

A. Dados e particionamento

É utilizado o Oxford-IIIT Pet, composto por imagens de 37 raças de cães e gatos, acompanhado de rótulos de classe e máscaras de segmentação [6]. O conjunto oficial de treino e validação é particionado de forma estratificada em 80% para treinamento e 20% para validação; o teste oficial permanece isolado. As imagens são redimensionadas e recortadas para 224×224 pixels, com normalização do ImageNet. No treinamento são aplicados recorte aleatório, espelhamento horizontal e pequenas variações de cor.

B. Estratégias de transferência

Os experimentos usam uma ResNet-18 com pesos do ImageNet e uma nova camada linear para 37 classes. Na estratégia *frozen*, o backbone permanece congelado e apenas o classificador é otimizado. Na estratégia *full*, todos os parâmetros são ajustados, usando taxa de aprendizado menor no backbone do que no classificador. AdamW, suavização de rótulos e decaimento cosseno da taxa de aprendizado são usados em ambas as condições.

Cada condição é executada com as sementes 42, 123 e 2026. O melhor checkpoint é escolhido pelo macro-F1 de validação. São reportados acurácia, macro-F1, balanced accuracy, erro esperado de calibração com dez intervalos e tempo de treinamento. Essa combinação evita que classes mais fáceis ou frequentes dominem a análise.

C. Grad-CAM e métricas espaciais

Para uma classe c , o peso do mapa de características A^k é obtido pela média espacial dos gradientes:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}. \quad (1)$$

O mapa Grad-CAM é então calculado por

$$L_{GC}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right), \quad (2)$$

e redimensionado para a resolução de entrada. O mapa é gerado para a classe predita por cada modelo na última convolução do bloco residual final.

DETALHES DE IMPLEMENTAÇÃO E REPRODUTIBILIDADE

O protocolo foi implementado em um notebook independente para execução no Google Colab, sem dependência do arquivo externo de experimento. A rotina de carregamento baixa o Oxford-IIIT Pet, constrói as partições estratificadas e aplica as transformações de treinamento e validação.

Para cada semente, o código instancia duas cópias da ResNet-18, treina primeiro a condição frozen e depois a condição full, selecionando o checkpoint de maior macro-F1 na validação. O mesmo conjunto de teste é usado para calcular as métricas preditivas e gerar os mapas Grad-CAM.

A comparação é pareada: os modelos de cada semente recebem a mesma divisão de dados e a mesma inicialização pseudoaleatória, diferindo apenas na política de atualização dos parâmetros. A análise registra classe predita, confiança e métricas espaciais por imagem.

Parâmetros principais

Parâmetro	Configuração
Arquitetura	ResNet-18 / ImageNet
Classes	37
Épocas	15
Sementes	42, 123, 2026
Grad-CAM	200 imagens por semente

Fluxo de execução

1. Fixar a semente e construir os loaders.
2. Treinar frozen e full por 15 épocas.
3. Selecionar o melhor checkpoint pela validação.
4. Avaliar classificação e calibração no teste.
5. Gerar Grad-CAM e métricas de alinhamento.
6. Agregar média e desvio-padrão dos três seeds.

Modos do notebook

O modo rápido usa uma época e uma fração pequena dos dados apenas para verificar a instalação. O modo completo usa o conjunto integral e 200 exemplos para Grad-CAM. Somente o modo completo foi utilizado nas tabelas do artigo.

Leitura dos resultados

O full obteve acurácia 0.8959 contra 0.8946 no frozen e aumentou energia no primeiro plano, pointing game e IoU de saliência. A melhora conjunta indica alinhamento ligeiramente maior com o animal, mas não constitui prova causal; um teste de oclusão do fundo permanece recomendado.

Tabela I
DESEMPENHO NO CONJUNTO DE TESTE (MÉDIA ± DESVIO-PADRÃO).

Estratégia	Acc.	Macro-F1	Bal. Acc.	ECE
Frozen	0.8946±.0026	0.8934±.0026	0.8939±.0027	0.1846±.0034
Full	0.8959±.0029	0.8948±.0026	0.8952±.0029	0.1793±.0078

Tabela II
ALINHAMENTO DO GRAD-CAM COM O ANIMAL.

Estratégia	Energia	Pointing	IoU
Frozen	0.7744±.0013	0.9833±.0029	0.3263±.0007
Full	0.8004±.0004	0.9900±.0087	0.3291±.0010

Três $\frac{1}{M}$ do animal. A *energia no primeiro plano* é a fração da intensidade do mapa contida em M ; o *pointing game* verifica se o máximo do mapa está no animal; e a IoU de saliência compara M com os 20% pixels de maior ativação. Para cada imagem também são calculadas a similaridade cosseno e a IoU entre as regiões mais salientes dos dois modelos.

As diferenças de métricas espaciais são calculadas por imagem, reduzindo a variabilidade causada pela composição do teste. Médias, desvios-padrão e intervalos de confiança por bootstrap serão apresentados, acompanhados de exemplos de

III. RESULTADOS

A Tabela I apresenta médias e desvios-padrão entre as três sementes. O ajuste completo elevou a acurácia de 0.8946 para 0.8959 e o macro-F1 de 0.8934 para 0.8948. A Tabela II mostra aumento nas três métricas espaciais: energia +0.0260, pointing game +0.0067 e IoU +0.0027. A similaridade cosseno média entre mapas foi 0.9497.

Há quatro resultados possíveis. Primeiro, ganho preditivo acompanhado de maior alinhamento com o animal indicaria adaptação útil das representações. Segundo, ganho de acurácia com menor alinhamento sugeriria exploração de correlações do fundo. Terceiro, mapas diferentes com desempenho semelhante mostrariam que modelos funcionalmente próximos podem usar evidências distintas. Finalmente, ausência de mudanças relevantes indicaria que as características pré-treinadas já são adequadas ao domínio.

O Grad-CAM possui resolução espacial limitada e não constitui explicação causal. A máscara informa onde está o animal, mas não quais partes distinguem uma raça; portanto, atenção no primeiro plano é uma condição desejável, não uma prova de raciocínio correto. Além disso, as duas estratégias usam taxas de aprendizado distintas por necessidade de otimização. Os resultados não devem ser generalizados para outras arquiteturas ou domínios sem novos experimentos.

Figura gerada automaticamente pelo experimento.

Figura 1. Exemplos de mapas Grad-CAM para backbone congelado e fine-tuning completo.

V. CONCLUSÃO

No Oxford-IIIT Pet, o ajuste completo produziu ganhos modestos de acurácia e macro-F1, reduziu o ECE e aumentou as três métricas de alinhamento do Grad-CAM com o animal. Assim, o fine-tuning alterou não apenas a acurácia, mas também as regiões salientadas, em direção a um alinhamento ligeiramente maior com o primeiro plano. O resultado não prova causalidade; a oclusão do fundo é um próximo teste.

REFERÊNCIAS

- [1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, 2012.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [3] S. Kornblith, J. Shlens, and Q. V. Le, "Do better imagenet models transfer better?" in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 2661–2671.
- [4] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Ba-tra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 618–626.
- [5] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, and B. Kim, "Sanity checks for saliency maps," in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [6] O. M. Parkhi, A. Vedaldi, A. Zisserman, and C. V. Jawahar, "Cats and dogs," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2012, pp. 3498–3505.