

Fine-Tuning e Regiões de Atenção em CNNs: Protocolo Experimental com Grad-CAM

Eduardo Jesus Dal Pizzol e Matheus Lemes Amaral

Universidade de Brasília (UnB)

FGA0261 - Inteligência Artificial II

Matrículas: 251008114 e 241031852

Resumo—Este trabalho propõe um protocolo para avaliar se o ajuste fino de uma rede neural convolucional altera não apenas seu desempenho preditivo, mas também as regiões da imagem usadas na classificação. Uma ResNet-18 pré-treinada no ImageNet é comparada em duas condições: extrator de características congelado e ajuste de todos os parâmetros. O desempenho é medido por acurácia, macro-F1, acurácia balanceada e erro esperado de calibração. O alinhamento espacial é avaliado com mapas de ativação de classe ponderados por gradientes (Grad-CAM) e máscaras de segmentação do Oxford-IIIT Pet. A execução reduzida preservada no projeto confirma o funcionamento do fluxo, mas não permite responder às perguntas de pesquisa. O experimento conclusivo requer três sementes aleatórias, treinamento completo e amostragem estratificada para a análise espacial.

Palavras-chave—redes neurais convolucionais, aprendizado por transferência, Grad-CAM, explicabilidade, ajuste fino

I. INTRODUÇÃO

Redes neurais convolucionais (CNNs) aprendem representações diretamente dos pixels e alcançam bons resultados em classificação visual [1]. Arquiteturas residuais facilitaram o treinamento de redes mais profundas e tornaram-se extratores de características amplamente utilizados em aprendizado por transferência [2]. Nesse cenário, um modelo pré-treinado em grande escala é adaptado para uma tarefa com menos dados, seja mantendo o extrator congelado, seja ajustando seus parâmetros.

O desempenho obtido na tarefa de origem não determina sozinho a qualidade da transferência [3]. Além disso, uma melhora de acurácia não demonstra que o modelo passou a usar evidências semanticamente adequadas: correlações do fundo podem sustentar uma predição correta. O Grad-CAM permite inspecionar a importância espacial derivada dos gradientes da classe [4], mas mapas visualmente plausíveis também devem ser interpretados com cautela [5].

Este estudo investiga duas perguntas. **RQ1**: o ajuste fino completo melhora a classificação em relação ao extrator congelado? **RQ2**: ele modifica o alinhamento da evidência visual com o animal? A contribuição é um protocolo reproduzível que combina métricas preditivas, calibração e medidas espaciais calculadas de forma pareada.

II. MATERIAIS E MÉTODOS

A. Dados e particionamento

O Oxford-IIIT Pet contém imagens de 37 raças de cães e gatos, rótulos de classe e máscaras de segmentação [6]. O

conjunto oficial *trainval* é particionado de forma estratificada em 80% para treinamento e 20% para validação; o teste oficial permanece isolado. As imagens são redimensionadas e recortadas para 224×224 pixels, com a normalização usada no ImageNet. No treinamento, aplicam-se recorte aleatório, espelhamento horizontal e pequenas variações de cor.

As máscaras possuem três valores: primeiro plano, fundo e região de contorno não classificada. Para evitar que a borda incerta seja contabilizada como parte do animal, somente os pixels rotulados explicitamente como primeiro plano são usados nas métricas espaciais.

B. Estratégias de transferência

Os experimentos usam uma ResNet-18 com pesos do ImageNet e uma nova camada linear para as 37 classes. Na condição *frozen*, o extrator permanece congelado e apenas o classificador é otimizado. Na condição *full*, todos os parâmetros são ajustados, com taxa de aprendizado menor no extrator do que no classificador. Ambas as condições usam AdamW, suavização de rótulos e decaimento cosseno da taxa de aprendizado.

Para uma comparação controlada, cada condição recebe a mesma divisão dos dados, a mesma inicialização do classificador e a mesma ordem inicial de minibatches. O melhor *checkpoint* é selecionado pelo macro-F1 de validação. O protocolo completo prevê as sementes 42, 123 e 2026, 15 épocas e todo o conjunto de treinamento.

C. Métricas preditivas e espaciais

São calculados acurácia, macro-F1, acurácia balanceada e erro esperado de calibração (ECE) com dez intervalos. O macro-F1 e a acurácia balanceada reduzem a influência de diferenças de dificuldade entre classes, enquanto o ECE compara confiança e frequência de acertos.

Para uma classe c , o peso do mapa de características A^k é obtido pela média espacial dos gradientes:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k}. \quad (1)$$

O mapa Grad-CAM é dado por

$$L_{GC}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right) \quad (2)$$

e redimensionado para a resolução de entrada.

Tabela I
VALIDAÇÃO FUNCIONAL PRESERVADA NO PROJETO (SEMENTE 42).

Condição	Acurácia	Macro-F1	ECE	Perda
<i>Frozen</i>	0,0000	0,0000	0,0729	4,8449
<i>Full</i>	0,0000	0,0000	0,0966	4,7307

O alinhamento com a máscara do animal é descrito por três medidas: energia do mapa no primeiro plano, *pointing game* e interseção sobre união (IoU) dos 20% de pixels mais salientes. A análise pareada também calcula a similaridade cosseno e a IoU entre os mapas das duas condições. Para reduzir viés de ordenação, as imagens destinadas ao Grad-CAM são escolhidas por amostragem estratificada entre as classes do teste.

III. IMPLEMENTAÇÃO E REPRODUTIBILIDADE

O protocolo está implementado em um notebook independente para Google Colab. O código baixa os dados, constrói as partições, treina as duas condições, seleciona os melhores *checkpoints*, avalia o teste e exporta tabelas, históricos e figuras. Resultados rápidos e completos são gravados separadamente. O agregador exige as três sementes antes de produzir médias e desvios-padrão, prepara um arquivo compactado e separa a figura destinada ao artigo.

IV. VALIDAÇÃO PRELIMINAR

Os únicos resultados preservados no projeto correspondem a uma validação funcional com uma época, 3% dos dados de treinamento, 16 imagens de teste e dois mapas Grad-CAM. A Tabela I registra os valores de classificação dessa execução. Eles verificam a passagem completa pelos componentes do sistema, mas não estimam o desempenho final dos modelos.

Os valores nulos de acurácia são compatíveis com uma verificação extremamente curta e não indicam falha do protocolo. Como apenas 16 exemplos foram avaliados, não se devem comparar as condições nem extrapolar esses números para o conjunto de teste completo.

A Figura 1 é identificada como diagnóstica porque contém apenas duas imagens da execução reduzida. As métricas espaciais dessa execução também não são reportadas, pois foram calculadas antes da correção do tratamento da borda das máscaras.

V. AMEAÇAS À VALIDADE E TRABALHO PENDENTE

O Grad-CAM tem resolução espacial limitada e não constitui explicação causal. A máscara informa onde está o animal, mas não quais partes distinguem uma raça. Portanto, maior atenção no primeiro plano é desejável, mas não prova que a decisão esteja correta. Testes de oclusão do fundo ou remoção controlada do primeiro plano seriam necessários para avaliar causalidade.

Antes de formular conclusões quantitativas, o notebook deve executar integralmente as três sementes e preservar configurações, históricos, métricas por amostra e resumos. O texto



Figura 1. Exemplos diagnósticos da execução reduzida. A figura confirma a geração dos mapas, mas não constitui evidência comparativa.

deverá ser atualizado exclusivamente a partir dos arquivos agregados, considerando a variação entre sementes.

VI. CONCLUSÃO

O projeto define um protocolo adequado para comparar ajuste fino completo e extração de características, incluindo desempenho preditivo, calibração e alinhamento espacial. A revisão corrigiu fatores que poderiam comprometer a comparação, como a interpretação da borda das máscaras, a ordem de minibatches e a seleção das imagens de Grad-CAM. No estado atual, entretanto, a execução preservada é apenas uma validação funcional; portanto, ainda não é possível responder de maneira sustentada às duas perguntas de pesquisa. A conclusão final depende da execução completa e da agregação rastreável das três sementes.

REFERÊNCIAS

- [1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "Imagenet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, 2012.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2016, pp. 770–778.
- [3] S. Kornblith, J. Shlens, and Q. V. Le, "Do better imagenet models transfer better?" in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 2661–2671.
- [4] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-cam: Visual explanations from deep networks via gradient-based localization," in *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 618–626.
- [5] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, and B. Kim, "Sanity checks for saliency maps," in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [6] O. M. Parkhi, A. Vedaldi, A. Zisserman, and C. V. Jawahar, "Cats and dogs," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2012, pp. 3498–3505.