

O Fine-Tuning Altera Apenas a Acurácia ou Também as Regiões Utilizadas por uma CNN?

Eduardo Jesus Dal Pizzol -- 251008114

Matheus Lemes Amaral -- 241031852

Universidade de Brasília -- UnB

FGA0261 -- Inteligência Artificial II

Resumo— O aprendizado por transferência é amplamente empregado em classificação de imagens, mas sua avaliação costuma se limitar ao desempenho preditivo. Este trabalho investiga se o ajuste completo de uma rede convolucional também modifica as regiões da imagem usadas em suas decisões. Uma ResNet-18 pré-treinada no ImageNet é avaliada no Oxford-IIIT Pet sob duas estratégias: extração de características com o backbone congelado e ajuste fino de todos os parâmetros. Além de acurácia, macro-F1 e calibração, mapas Grad-CAM são comparados com as máscaras de segmentação dos animais por energia no primeiro plano, pointing game e interseção sobre união. Os resultados são agregados sobre três sementes e analisados de forma pareada.

Palavras-chave— redes neurais convolucionais, transferência de aprendizado, fine-tuning, Grad-CAM, explicabilidade

I. INTRODUÇÃO

Redes neurais convolucionais (CNNs) transformaram a classificação visual ao aprender representações diretamente dos pixels [1]. Arquiteturas residuais permitiram treinar modelos mais profundos e tornaram-se backbones comuns em aprendizado por transferência [2]. Nesse cenário, um modelo pré-treinado em grande escala é adaptado para uma tarefa com menos dados, congelando o extrator de características ou ajustando seus parâmetros.

Embora modelos com melhor desempenho no ImageNet geralmente apresentem melhor transferência, essa relação depende da tarefa e do procedimento de adaptação [3]. Comparações baseadas somente em acurácia não mostram se o modelo aprendeu evidências semanticamente adequadas. Uma CNN pode melhorar a classificação explorando correlações do fundo em vez das características do objeto.

O Grad-CAM produz mapas de importância espacial a partir dos gradientes da classe em relação às ativações convolucionais [4]. Entretanto, mapas visualmente plausíveis não são evidência suficiente de explicabilidade, pois alguns métodos de saliência podem ser pouco sensíveis aos parâmetros aprendidos [5]. Por isso, este trabalho combina inspeção qualitativa e métricas calculadas contra máscaras de segmentação.

São investigadas duas perguntas: **RQ1:** o fine-tuning completo melhora a classificação em relação ao backbone congelado? **RQ2:** ele altera a localização da evidência visual e seu alinhamento com o animal? A contribuição é um protocolo reproduzível que relaciona desempenho, calibração e atenção espacial em pares de modelos com a mesma arquitetura e inicialização pré-treinada.

II. MATERIAIS E MÉTODOS

A. Dados e particionamento

É utilizado o Oxford-IIIT Pet, composto por imagens de 37 raças de cães e gatos, acompanhado de rótulos de classe e máscaras de segmentação [6]. O conjunto oficial de treino e validação é particionado de forma estratificada em 80% para treinamento e 20% para validação; o teste oficial permanece isolado. As imagens são redimensionadas e recortadas para 224×224 pixels, com normalização do ImageNet. No treinamento são aplicados recorte aleatório, espelhamento horizontal e pequenas variações de cor.

B. Estratégias de transferência

Os experimentos usam uma ResNet-18 com pesos do ImageNet e uma nova camada linear para 37 classes. Na estratégia *frozen*, o backbone permanece congelado e apenas o classificador é otimizado. Na estratégia *full*, todos os parâmetros são ajustados, usando taxa de aprendizado menor no backbone do que no classificador. AdamW, suavização de rótulos e decaimento cosseno da taxa de aprendizado são usados em ambas as condições.

Cada condição é executada com as sementes 42, 123 e 2026. O melhor checkpoint é escolhido pelo macro-F1 de validação. São reportados acurácia, macro-F1, balanced accuracy e erro esperado de calibração com dez intervalos.

C. Grad-CAM e métricas espaciais

Para uma classe c , o peso do mapa de características A^k é obtido pela média espacial dos gradientes: $\alpha_k^c = (1/Z) \sum_{ij} \partial y^c / \partial A_{ij}^k$. O mapa é então $L_{GC}^c = \text{ReLU}(\sum_k \alpha_k^c A^k)$ e é redimensionado para a resolução de entrada. O mapa é gerado para a classe predita na última convolução do bloco residual final.

Três métricas avaliam o alinhamento com a máscara M do animal. A *energia no primeiro plano* é a fração da intensidade do mapa contida em M ; o *pointing game* verifica se o máximo do mapa está no animal; e a IoU de saliência compara M com os 20% pixels de maior ativação. Também são calculadas a similaridade cosseno e a IoU entre as regiões mais salientes dos dois modelos.

III. IMPLEMENTAÇÃO E REPRODUTIBILIDADE

O protocolo foi implementado em um notebook independente para execução no Google Colab. A função de carregamento baixa o Oxford-IIIT Pet, constrói as partições estratificadas e aplica as transformações de treinamento e validação. Para cada semente, são instanciadas duas cópias da ResNet-18, treinadas nas condições *frozen* e *full*; o checkpoint de maior macro-F1 na validação é selecionado. Em seguida, o mesmo conjunto de teste é usado para calcular as métricas preditivas e gerar os mapas Grad-CAM.

A comparação é pareada: os modelos de cada semente recebem a mesma divisão de dados e a mesma inicialização pseudoaleatória, diferindo apenas na política de atualização dos parâmetros. A análise registra classe predita, confiança

e métricas espaciais por imagem. Uma rotina de agregação calcula as médias e os desvios-padrão usados nas tabelas.

Tabela I — Parâmetros principais da implementação.

Parâmetro	Configuração
Arquitetura	ResNet-18, pesos ImageNet
Classes	37 raças de cães e gatos
Épocas no modo completo	15
Sementes	42, 123 e 2026
Exemplos para Grad-CAM	200 por semente

Para reduzir o risco de confundir uma falha de instalação com um resultado científico, o notebook possui dois modos. O modo rápido usa uma época e uma fração pequena dos dados apenas para verificar o fluxo; o modo completo usa 15 épocas, o conjunto integral e 200 exemplos para Grad-CAM. Somente o segundo modo é utilizado nas tabelas e na discussão.

IV. RESULTADOS

Tabela II — Desempenho no conjunto de teste (média $\pm$ desvio-padrão).

Estratégia	Acc.	Macro-F1	Bal. Acc.	ECE
Frozen	0.8946 $\pm$ 0.0026	0.8934 $\pm$ 0.0026	0.8939 $\pm$ 0.0027	0.1846 $\pm$ 0.0034
Full	0.8959 $\pm$ 0.0029	0.8948 $\pm$ 0.0026	0.8952 $\pm$ 0.0029	0.1793 $\pm$ 0.0078

O fine-tuning completo elevou a acurácia de 0.8946 para 0.8959 (diferença de +0.0013) e o macro-F1 de 0.8934 para 0.8948. A balanced accuracy apresentou comportamento semelhante. O ECE diminuiu de 0.1846 para 0.1793, indicando uma pequena melhora de calibração, embora a diferença seja modesta diante da variabilidade entre sementes.

Tabela III — Alinhamento do Grad-CAM com o animal.

Estratégia	Energia	Pointing	IoU
Frozen	0.7744 $\pm$ 0.0013	0.9833 $\pm$ 0.0029	0.3263 $\pm$ 0.0007
Full	0.8004 $\pm$ 0.0004	0.9900 $\pm$ 0.0087	0.3291 $\pm$ 0.0010

As três métricas espaciais aumentaram no ajuste completo: a energia no primeiro plano cresceu 0.0260, o pointing game cresceu 0.0067 e a IoU de saliência cresceu 0.0027. A similaridade cosseno média entre os mapas foi 0.9497 e a IoU entre suas regiões de maior ativação foi 0.6301, indicando mapas bastante semelhantes, mas não idênticos.

A Figura 1 mostra exemplos de mapas Grad-CAM para os dois modelos. O resultado conjunto indica que, neste protocolo, o aumento de acurácia não veio acompanhado de pior alinhamento espacial; ao contrário, houve uma melhora pequena nos indicadores de localização.




Figura 1 — Exemplos de mapas Grad-CAM para backbone congelado e fine-tuning completo.

V. DISCUSSÃO

O ganho preditivo acompanhado de maior alinhamento com o animal é compatível com uma adaptação útil das representações. Os mapas, contudo, não são explicações causais: a máscara informa onde está o animal, mas não quais partes distinguem uma raça. Portanto, atenção no primeiro plano é uma condição desejável, não uma prova de raciocínio correto.

Embora os resultados observados não indiquem maior dependência do fundo, as estratégias usam taxas de aprendizado distintas por necessidade de otimização. Um teste de ablação ou oclusão do fundo seria necessário para estabelecer causalidade. Os resultados não devem ser generalizados para outras arquiteturas ou domínios sem novos experimentos.

VI. CONCLUSÃO

No Oxford-IIIT Pet, o ajuste completo produziu ganhos modestos de acurácia e macro-F1, reduziu o ECE e aumentou as três métricas de alinhamento do Grad-CAM com o animal. Assim, para este protocolo, o fine-tuning alterou não apenas a acurácia, mas também as regiões salientadas, em direção a um alinhamento ligeiramente maior com o primeiro plano. A conclusão é restrita ao conjunto de dados, à arquitetura e às sementes utilizadas; experimentos de oclusão do fundo são um próximo passo para testar se essa associação é causal.

REFERÊNCIAS

- [1] A. Krizhevsky, I. Sutskever, and G. E. Hinton, "ImageNet classification with deep convolutional neural networks," in *Advances in Neural Information Processing Systems*, vol. 25, 2012.
- [2] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of CVPR*, 2016, pp. 770-778.
- [3] S. Kornblith, J. Shlens, and Q. V. Le, "Do better ImageNet models transfer better?" in *Proceedings of CVPR*, 2019, pp. 2661-2671.
- [4] R. R. Selvaraju et al., "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proceedings of ICCV*, 2017, pp. 618-626.
- [5] J. Adebayo et al., "Sanity checks for saliency maps," in *Advances in Neural Information Processing Systems*, vol. 31, 2018.
- [6] O. M. Parkhi, A. Vedaldi, A. Zisserman, and C. V. Jawahar, "Cats and dogs," in *Proceedings of CVPR*, 2012, pp. 3498-3505.